

GLOBAL PROJECT

PROGRAMA:

MÁSTER EN BIG DATA Y DATA SCIENCE

NOMBRE DEL PROYECTO:

Optimización predictiva del consumo energético mediante Inteligencia Artificial en comunidades energéticas locales

AUTOR:

Carlos Romero Vázquez

[Link al Drive para ver la presentación e información adicional](#)

Contenido

1. RESUMEN	2
2. INTRODUCCIÓN	3
3. ESTADO DEL ARTE	6
4. OBJETIVOS	10
5. SOLUCIÓN PLANTEADA	11
5.1. Metodología.....	11
5.2. Desarrollo de cada etapa	12
Etapa 1. Estudio y preparación del dataset	12
Etapa 2. Ingeniería de características (feature engineering)	17
Etapa 3. Selección de características	18
Etapa 4. Modelado y entrenamiento.....	20
Etapa 5. Transferibilidad y validación cruzada.....	22
6. EVALUACIÓN	26
6.1. Evaluación en la selección de características	26
6.2. Evaluación del rendimiento de los modelos	27
6.3. Evaluación de la transferibilidad de los modelos	28
7. RESULTADOS	29
8. CONCLUSIONES Y TRABAJOS FUTUROS	34
9. REFERENCIAS.....	36

1. RESUMEN

El crecimiento de las comunidades energéticas locales y la penetración creciente de energías renovables plantean nuevos retos en la predicción de la demanda eléctrica, debido a la alta variabilidad del consumo y a la necesidad de gestionar la flexibilidad del sistema. La falta de modelos capaces de integrar de forma eficiente la información histórica de consumo con variables exógenas, como la meteorología o el comportamiento colectivo, dificulta la estabilidad y el aprovechamiento de recursos en las comunidades energéticas locales.

Para dar respuesta a este problema, se planteó como solución el desarrollo de modelos predictivos basados en técnicas de aprendizaje automático y aprendizaje profundo, con énfasis en arquitecturas neuronales avanzadas (LSTM, DenseNN, TCN) y en la comparación con modelos más tradicionales como Random Forest. La metodología incluyó un proceso sistemático de selección de variables, pruebas de transferencia de modelos entre comunidades diferentes y la incorporación de innovaciones como la variable de la hora solar, que aporta un modo más eficiente y económico de capturar la variación geográfica de la radiación respecto al uso de la hora simple.

La justificación de esta solución radica en la necesidad de combinar precisión con coste computacional reducido, aspectos clave para la gestión práctica de comunidades energéticas. El uso de datos reales procedentes de comunidades energéticas ha permitido validar la propuesta en escenarios heterogéneos.

Los resultados obtenidos demuestran que los modelos basados en Random Forest y LSTM alcanzan valores de R^2 bastante elevados, superando 0,90 en predicciones de corto plazo. Además, la introducción de la hora solar como variable explicativa constituye un hallazgo novedoso que mejora la capacidad predictiva frente al uso de la hora simple. En conjunto, se constata que la solución propuesta contribuye a optimizar la gestión de la demanda, favoreciendo la integración de energías renovables y la eficiencia de las redes inteligentes.

2. INTRODUCCIÓN

El problema identificado en este proyecto se centra en la predicción del consumo eléctrico en comunidades energéticas locales, un reto de gran relevancia en el contexto actual de transición hacia las Smart Grids y de impulso de la generación distribuida. Esta necesidad se detectó tras analizar la importancia que el pronóstico de la demanda tiene en la literatura reciente y en proyectos reales, donde se evidencia que disponer de previsiones fiables resulta esencial para optimizar la operación, reducir costes de gestión y favorecer la integración de fuentes renovables en el mix energético. La ausencia de herramientas predictivas adaptadas específicamente a las comunidades energéticas locales genera ineficiencias y limita la capacidad de planificación de sus participantes.

Tradicionalmente, este problema ha sido abordado mediante métodos estadísticos clásicos como ARIMA o SARIMAX, que han demostrado eficacia en entornos con patrones lineales y estacionales bien definidos. Más recientemente, los avances en inteligencia artificial han impulsado el uso de modelos de machine learning como Random Forest y redes neuronales recurrentes (RNN, LSTM), que han mostrado una mayor capacidad para capturar relaciones no lineales y dependencias a largo plazo en series temporales. Sin embargo, la literatura muestra que muchos de estos enfoques presentan limitaciones a la hora de incorporar variables contextuales novedosas, como aquellas que tienen en cuenta el ciclo solar ajustado a la ubicación geográfica de la comunidad. Asimismo, la transferibilidad de los modelos entre diferentes comunidades energéticas locales todavía es un área poco explorada, lo que abre un espacio de innovación para este proyecto.

La solución planteada consiste en el desarrollo de un marco comparativo de modelos predictivos que abarca desde enfoques clásicos como ARIMA hasta arquitecturas avanzadas de deep learning (LSTM, CNN, combinaciones secuencia-contexto). Este marco está diseñado para evaluar, bajo condiciones homogéneas, la capacidad de los distintos modelos para predecir el siguiente valor de la serie de consumo eléctrico. Además, el enfoque contempla la posibilidad de incorporar o excluir variables externas relacionadas con el tiempo atmosférico (temperatura, radiación solar, humedad), así como variables derivadas de la propia serie: hora cíclica y día laborable/festivo.

Esta propuesta resulta especialmente adecuada e innovadora porque introduce, de forma diferencial, la hora solar cíclica basada en la latitud y longitud de la comunidad. Esta variable permite ajustar los patrones de consumo a los ciclos solares locales, representando de manera más fiel la influencia de la luz natural en los hábitos de los usuarios. Se trata de una aportación apenas explorada en la literatura, que ofrece un nivel de granularidad superior frente a variables temporales tradicionales y que, por tanto, se postula como una contribución original y valiosa del proyecto.

Para evaluar esta solución, se ha seguido un procedimiento estructurado en varias fases:

1. Estudio del estado del arte: se realizó una revisión sistemática de la literatura científica y de proyectos internacionales recientes, con el fin de identificar metodologías, arquitecturas

de modelos y variables comúnmente utilizadas en forecasting eléctrico. Este análisis permitió enmarcar la propuesta en el contexto de la investigación actual y detectar vacíos en los que situar la aportación del proyecto.

2. Búsqueda, selección y preparación de datasets: se trabajó con datos procedentes de comunidades energéticas y de series de consumo eléctrico abiertas. El proceso incluyó la recopilación, limpieza, estandarización y transformación de los datos, asegurando que estuvieran en un formato adecuado para alimentar modelos de distinta naturaleza. Se diseñaron variables adicionales que enriquecieron la serie temporal, permitiendo capturar dependencias más complejas.
3. Ingeniería de características sistemática: se aplicaron de forma complementaria tres técnicas para explorar la relación entre predictores y variable objetivo: la correlación de Pearson y Spearman (`pandas.DataFrame.corr`), la importancia por impureza derivada de Random Forest, y la importancia por permutación. Este enfoque permitió no solo seleccionar las variables más relevantes, sino también clasificarlas entre obligatorias, candidatas y descartables, asegurando una fundamentación estadística y empírica sólida en la construcción del modelo.
4. Entrenamiento y comparación de modelos: se entrenaron distintos algoritmos bajo condiciones homogéneas de evaluación, utilizando métricas estandarizadas (MSE, RMSE, R^2 , MAPE) y medición de los tiempos de entrenamiento. Esta comparación rigurosa permitió identificar, no solo el rendimiento en términos de precisión, sino también el coste computacional asociada a cada modelo, un aspecto clave para la escalabilidad en dispositivos de bajo consumo de recursos.
5. Pruebas de transferibilidad: se realizaron experimentos inspirados en las técnicas de transfer learning aplicadas a forecasting energético, aplicando modelos entrenados en una comunidad a otras distintas. Esto permitió analizar hasta qué punto los patrones aprendidos en un entorno son reutilizables en otro, generando evidencias sobre la viabilidad práctica de extender las soluciones más allá de un único dataset.

Los resultados iniciales muestran que los modelos basados en redes neuronales LSTM y CNN, especialmente al incorporar las variables cíclicas y, en particular, la hora solar, logran mejorar significativamente la precisión frente modelos neuronales más sencillos. Asimismo, los experimentos de transferibilidad demuestran que es posible reutilizar modelos entrenados en diferentes comunidades, lo que abre perspectivas de aplicación en comunidades energéticas carentes de registros previos de datos.

Este proyecto ha supuesto también un salto formativo notable, puesto que se han ampliado competencias en diversos ámbitos: búsqueda y análisis crítico de datasets, profundización en la literatura científica sobre forecasting eléctrico, aplicación de técnicas de ingeniería de características avanzadas, experimentación con arquitecturas neuronales novedosas y trabajo intensivo con series temporales. Estos aprendizajes complementan de forma significativa los contenidos previamente abordados en el máster, posicionando al alumno autor del Global Project en un área de alta demanda en el sector energético y en la ciencia de datos aplicada.

Finalmente, la estructura del presente documento se organiza de la siguiente manera:

- I. Estado del Arte: en este apartado se recopilan proyectos o publicaciones científicas relevantes que abordan la predicción del consumo eléctrico y su aplicación en comunidades energéticas. Se analizan distintos enfoques metodológicos —desde los modelos estadísticos clásicos hasta las técnicas de deep learning más recientes— y se justifica, a la luz de esta literatura, la pertinencia de la solución planteada. El capítulo concluye con un sub-apartado de conclusiones, donde se resalta el carácter innovador de la propuesta y el aporte de nuevo conocimiento en comparación con trabajos previos.
- II. Objetivos: se define en primer lugar el objetivo general, enfocado en diseñar y evaluar un marco comparativo de modelos predictivos para el consumo eléctrico en comunidades energéticas locales. A continuación, se detallan los objetivos específicos, que describen cómo se ha llevado a cabo este propósito: desde la construcción y preparación de datasets, hasta el diseño de variables innovadoras como la hora solar cíclica, la implementación de modelos diversos y la validación de su transferibilidad.
- III. Solución Planteada: este apartado describe con detalle la propuesta metodológica. Comienza con la metodología de trabajo, estructurada en cinco etapas principales: recopilación y preparación de datos, ingeniería de características, entrenamiento de modelos, comparación sistemática de métricas y pruebas de transferibilidad. Después, se desarrolla en profundidad cada una de estas etapas, explicando las técnicas empleadas, su validación en la literatura y su aplicación en el contexto del proyecto.
- IV. Evaluación: se expone el proceso seguido para validar la solución. La evaluación se ha basado en una metodología reconocida y respaldada por la comunidad científica, con la aplicación de métricas estándar (MSE, RMSE, R^2 , MAPE) y técnicas de validación cruzada. Además, también se justifica la elección de estas métricas y se explica cómo se interpretan los resultados en términos de precisión, generalización y eficiencia computacional.
- V. Resultados: en este capítulo se presentan los resultados obtenidos de la evaluación de los modelos. La presentación se realiza utilizando notación científica estándar, acompañada de tablas, gráficas y análisis comparativos. Se destacan los modelos que han mostrado mejor rendimiento, el impacto de incluir o no variables de contexto, y la influencia de la hora solar cíclica en la mejora de la predicción.
- VI. Conclusiones y Trabajos Futuros: es el último apartado y en él se sintetizan los hallazgos más relevantes del proyecto, evaluando hasta qué punto se cumplieron los objetivos planteados. Asimismo, se proponen posibles líneas de desarrollo futuro, como la implementación de arquitecturas híbridas más avanzadas o la validación del modelo en comunidades energéticas reales.

3. ESTADO DEL ARTE

La predicción de la demanda eléctrica constituye un campo de investigación de enorme relevancia en el marco de la transición energética y el despliegue de las comunidades energéticas locales. La creciente integración de recursos renovables, el auge de la generación distribuida y la electrificación de la demanda, plantean la necesidad de contar con modelos precisos, adaptables y explicativos. En este sentido, la literatura académica refleja un esfuerzo continuado por desarrollar técnicas avanzadas que permitan anticipar consumos a distintas escalas temporales y espaciales, equilibrando precisión, costes computacionales e interpretabilidad.

Este apartado revisa las principales aportaciones en el ámbito de la predicción de la demanda eléctrica, organizadas en torno a tres ejes que se relacionan directamente con los objetivos de este trabajo: (1) la identificación y uso de variables relevantes más allá de la serie histórica, (2) la búsqueda de arquitecturas de modelado avanzadas que superen a los enfoques tradicionales, y (3) la exploración de la transferibilidad de modelos entre comunidades energéticas.

Variables y factores que enriquecen la predicción

La literatura coincide en que el uso exclusivo de la serie histórica de consumo resulta insuficiente en contextos caracterizados por alta variabilidad y penetración renovable. Diversas revisiones sistemáticas han puesto de manifiesto la importancia de integrar factores exógenos. Nti et al. (Kofi Nti, Teimeh, Nyarko-Boateng, & Adekoya, 2020) analizaron 77 estudios de predicción de demanda publicados entre 2010 y 2020, concluyendo que más del 50% de los modelos incorporaban variables meteorológicas o socioeconómicas, siendo la temperatura, la humedad y la estacionalidad diaria/semanal las más frecuentes. En América Latina, Mazzeo et al. (Mazzeo, Sepúlveda-Cano, F. Villa, & Gallego-Burgos, 2019) confirmaron esta tendencia, destacando además la necesidad de evaluar el impacto de cada variable para evitar redundancia y costes computacionales innecesarios.

En el plano aplicado, Uppal et al. (Uppal, Kumar Garg, & Kumar, 2020) en India propusieron un modelo “weather-biased” que incorpora explícitamente índices de calor, viento y humedad, demostrando mejoras notables en entornos desregulados. De forma similar, Torres Sánchez (Torres Sánchez, 2023) comparó modelos ARIMA, SARIMAX, Random Forest y LSTM con y sin variables exógenas, observando que la introducción de la temperatura y del “tipo de día” reducía los errores significativamente.

Estos hallazgos respaldan el **primer objetivo del proyecto**, orientado a explorar sistemáticamente variables derivadas de la temporalidad, la meteorología y el comportamiento comunitario. No se trata solo de añadir información, sino de evaluar qué combinaciones permiten mejorar la capacidad predictiva manteniendo un balance entre complejidad y eficiencia computacional.

Modelos tradicionales frente a arquitecturas neuronales avanzadas

Durante décadas, los modelos estadísticos como ARIMA y SARIMAX han sido la base de la predicción de demanda. Sin embargo, múltiples investigaciones evidencian que técnicas de *machine learning* y *deep learning* ofrecen ventajas en contextos no lineales y de alta frecuencia de datos. Ahmad et al. (Waseem Ahmad, Mourshed, & Rezgui, 2017) compararon Random Forest y redes neuronales en la predicción de consumo energético de edificios en Reino Unido, observando que las ANN ofrecían ligeras mejoras en precisión, mientras que los bosques aleatorios resultaban más fáciles de ajustar.

En el caso español, Torres et al. (F. Torres, Martínez-Álvarez, & A., 2021) aplicaron LSTM optimizadas mediante un algoritmo metaheurístico inspirado en la propagación del SARS-CoV-2, alcanzando un error inferior al 1,5% en predicciones a cuatro horas. Lara-Benítez et al. (Lara-Benítez, Carranza-García, M. Luna-Romera, & C. Riquelme, 2020), por su parte, introdujeron las *Temporal Convolutional Networks* (TCN), demostrando que estas superaban a las LSTM en precisión y estabilidad de entrenamiento en series energéticas.

Estos resultados consolidan un consenso:

- Modelos densos ofrecen simplicidad pero limitaciones en secuencias largas.
- Redes recurrentes (LSTM) destacan en la captura de dependencias temporales, aunque con elevados costes de entrenamiento.
- Redes convolucionales causales dilatadas (TCN) presentan ventajas en escalabilidad y paralelización, lo que las convierte en candidatas prometedoras para predicción en tiempo real.

La literatura confirma así la pertinencia del **segundo objetivo del proyecto**, orientado a contrastar arquitecturas neuronales con modelos de referencia como Random Forest o SARIMAX, siguiendo una estrategia de incorporación progresiva de características para medir su efecto real en las predicciones.

Transferibilidad y generalización entre comunidades

La transferibilidad de modelos es un campo emergente en la investigación energética. La escasez de datos en determinadas comunidades hace inviable entrenar modelos propios, lo que ha motivado la adopción de enfoques de *transfer learning*. Laitsos et al. (Laitsos, y otros, 2024) aplicaron técnicas de transferencia profunda en islas griegas, mostrando que modelos preentrenados y posteriormente afinados con datos locales lograban MAPE inferiores al 6%, superando incluso a modelos entrenados desde cero.

Este enfoque resulta particularmente atractivo para comunidades energéticas locales, caracterizadas por conjuntos de datos reducidos, heterogéneos y sensibles a cambios en la participación de los prosumidores (productores y consumidores). La investigación de Herzen (Herzen, 2022) refuerza esta perspectiva al destacar que la reutilización de modelos en distintos dominios reduce costes de entrenamiento y facilita la generalización.

El **tercer objetivo del proyecto** se alinea con esta corriente, al proponer la evaluación de la transferibilidad entre comunidades a partir de distintas transformaciones de las series (valores absolutos, deltas, deltas suavizados). Este planteamiento no solo busca mejorar la capacidad de adaptación de los modelos, sino también ofrecer un marco práctico para extender soluciones predictivas a comunidades con baja disponibilidad de datos.

Smart Grids, Big Data y el marco normativo

Más allá de la técnica, el estado del arte refleja un marco institucional y tecnológico en el que se inserta la predicción de la demanda. En España, informes como el de FutuRed (FutuRed & Boston Consulting Group, 2012) ya señalaban que el despliegue de redes inteligentes podía generar beneficios económicos entre 2 y 3,5 veces superiores a la inversión inicial. El VII Congreso de Smart Grids (Grupo Tecma Red & SmartGridsInfo, 2020) reforzó esta visión, destacando la digitalización, el autoconsumo y las comunidades locales como ejes de la transición energética.

A nivel internacional, el informe ISGAN 2024 (International Smart Grid Action Network) (International Smart Grid Action Network (ISGAN), 2025) subraya la importancia de la digitalización, la interoperabilidad y la resiliencia como pilares de las redes inteligentes del futuro. Paralelamente, el auge de técnicas de *big data* ha permitido gestionar volúmenes crecientes de información en tiempo real. Melgar et al. (Melgar García, Torres Maldonado, Troncoso, & Riquelme Santos, 2024) muestran cómo la combinación de IA y Big Data facilita la predicción simultánea de demanda y precios eléctricos, aportando capacidad de reacción ante mercados volátiles.

Este contexto confirma que la investigación en predicción no es solo una cuestión algorítmica, sino también una necesidad estratégica alineada con la política energética y la sostenibilidad.

Conclusiones del estado del arte

De la revisión se desprenden varias conclusiones relevantes:

1. **Relevancia de nuevas variables:** la literatura demuestra que factores meteorológicos, socioeconómicos y comunitarios enriquecen la predicción, aunque requieren un análisis selectivo para equilibrar precisión y eficiencia.
2. **Superioridad de arquitecturas avanzadas:** modelos como LSTM y TCN superan en algunos aspectos a los enfoques tradicionales en escenarios de alta variabilidad y datos de alta frecuencia.
3. **Transferibilidad como línea emergente:** el *transfer learning* aparece como una vía prometedora para comunidades con limitados recursos de datos.
4. **Entorno digital y normativo:** el despliegue de smart grids y comunidades locales sitúa la predicción de demanda como un elemento estratégico de la transición energética.

En este contexto, el presente proyecto se sitúa en la intersección de estas brechas de conocimiento, al proponer la exploración de modelos avanzados de predicción en comunidades energéticas locales, incorporando variables exógenas, y evaluando no solo la exactitud técnica,

sino también la utilidad práctica de las predicciones para los actores implicados en la gestión energética.

Además, se detectó un vacío en la literatura respecto a la generación de variables simples pero informativas derivadas de la hora y la posición geográfica, que permiten conocer con claridad la evolución del horario solar con un coste computacional mínimo. Explorar si estas transformaciones de bajo coste podían aportar mejoras significativas en la precisión de las predicciones representa un aporte adicional al campo, al combinar eficiencia y aplicabilidad práctica. Con ello se contribuye a un campo poco explorado en la literatura y se genera un aporte de nuevo conocimiento aplicable a la transición energética sostenible.

4. OBJETIVOS

El objetivo general de este Global Project es estudiar y aportar mejoras a la predicción de la demanda en comunidades energéticas locales, mediante la búsqueda de los modelos y arquitecturas más adecuados, la incorporación de nuevas variables que recojan la influencia del entorno y el comportamiento colectivo, y la capacidad de transferibilidad de modelos ya entrenados a nuevas comunidades locales.

Para alcanzar este propósito, el proyecto se plantea varios objetivos específicos:

1. Búsqueda de variables para mejorar la predicción.

Se realiza una búsqueda sistemática de variables con el fin de enriquecer los modelos. Este proceso contempla la identificación de nuevas características derivadas de la temporalidad, la meteorología o el comportamiento de la propia comunidad, explorando cómo estas pueden mejorar la capacidad predictiva respecto al uso exclusivo de la serie histórica de consumo. El objetivo es crear una base de conocimiento para identificar patrones ocultos y relaciones no evidentes entre las variables.

2. Búsqueda de redes neuronales que igualen o superen a modelos más tradicionales.

El segundo objetivo consiste en evaluar distintas arquitecturas de redes neuronales y compararlas con modelos de referencia ya consolidados, como los Random Forest o los modelos SARIMAX. Para ello se exploran modelos densos (Dense Networks), redes recurrentes tipo LSTM y arquitecturas más avanzadas como las redes convolucionales causales dilatadas con conexiones residuales (TCN). El análisis se llevará a cabo siguiendo una estrategia de selección aditiva de características midiendo su efecto real en la mejora de las predicciones.

3. Comprobar la transferibilidad entre comunidades.

Este objetivo se centra en analizar la capacidad de transferibilidad de los modelos, es decir, su posibilidad de reutilización en diferentes contextos locales. Se busca comprobar si un modelo entrenado en una determinada comunidad energética puede ser aplicado en otra que no tenga datos suficientes para entrenar su propio modelo. Para ello se evalúa la generalización de modelos entrenados tanto sobre valores absolutos como sobre series transformadas en deltas y deltas suavizados, explorando si estas variaciones permiten reducir errores y facilitar la adaptación a nuevas comunidades.

4. Adquisición de competencias formativas y profesionales.

No podemos olvidar que el proyecto global de un máster también cumple objetivos de carácter formativo y profesional, ya que se orienta a consolidar las competencias adquiridas durante el máster. Esto incluye la aplicación de técnicas avanzadas de procesamiento de datos, el diseño y validación de modelos predictivos, el análisis crítico de resultados y la comunicación efectiva de las conclusiones. De este modo, el proyecto tiene como objetivo integrar conocimientos técnicos y analíticos con habilidades transversales. Además, al abordar un problema de regresión de series temporales, se ha extendido el temario del máster.

5. SOLUCIÓN PLANTEADA

En este apartado se expone la solución planteada, iniciando con la metodología adoptada para su desarrollo. Dicha metodología se fundamenta en enfoques validados por la comunidad científica. A continuación, se describen de manera estructurada las etapas que conforman el proceso, detallando los pasos seguidos en cada una de ellas. Posteriormente, se presenta el desarrollo específico de cada etapa, con el propósito de ofrecer una visión clara, coherente y justificada de la estrategia implementada.

5.1. Metodología

La solución propuesta para abordar la predicción de la demanda en comunidades energéticas locales se fundamenta en una metodología basada en enfoques validados por la comunidad científica en el ámbito del análisis de series temporales y de la modelización energética. Esta metodología se inspira en las recomendaciones derivadas de revisiones sistemáticas sobre forecasting energético y en trabajos recientes que demuestran la necesidad de combinar técnicas tradicionales, algoritmos de aprendizaje automático y modelos de *deep learning* especializados.

El esquema metodológico seguido consta de cinco etapas principales, cada una con objetivos específicos:

- **Etapas 1: Estudio y preparación de los datos.** Comprender la naturaleza del dataset y establecer una señal representativa de la comunidad energética que sirviera como variable objetivo.
- **Etapas 2: Ingeniería de características (feature engineering).** Incorporar variables relevantes, tanto endógenas (derivadas de la propia serie de consumo) como exógenas (meteorológicas, calendario), capaces de reflejar patrones estacionales y condiciones externas.
- **Etapas 3: Selección de características.** Identificar el conjunto de predictores más influyentes mediante la combinación de distintos métodos de selección y la posterior agregación de resultados, evitando la dependencia de un único criterio.
- **Etapas 4: Modelado y entrenamiento.** Entrenar y comparar diferentes aproximaciones, desde modelos de referencia rápidos hasta redes neuronales profundas diseñadas para secuencias, evaluando sistemáticamente su rendimiento.
- **Etapas 5: Transferibilidad y validación cruzada.** Explorar la capacidad de los modelos entrenados para generalizar a otros contextos geográficos o datasets, aplicando técnicas de *transfer learning* y ajustando el preprocesamiento en función de la calidad de los datos.

Esta metodología responde a una visión integradora: no solo busca construir un modelo predictivo eficaz en términos de error, sino también garantizar que las decisiones de diseño se

apoyen en fundamentos teóricos, prácticas contrastadas y un equilibrio entre precisión, interpretabilidad y eficiencia computacional.

Todo el procesamiento de datos, el análisis exploratorio (EDA), así como el entrenamiento y la evaluación de los modelos, se llevaron a cabo en Google Colab usando Python y las librerías principales Numpy, Pandas, TensorFlow, Seaborn y Matplotlib.

5.2. Desarrollo de cada etapa

Etapa 1. Estudio y preparación del dataset




El punto de partida fue el análisis del conjunto de datos de Loureiro, Portugal (Monteiro, y otros, Electricity consumption dataset of a local energy cooperative, 2024), correspondiente al consumo de una comunidad energética local. El dataset recoge la información de 172 sensores de consumo eléctrico distribuidos en viviendas y entidades de la comunidad, es decir, se encuentran geográficamente cerca unos de otros.

El conjunto de datos se encuentra en un archivo CSV con 172 columnas (*Energy_Meter_N*, $1 \leq N \leq 172$) con los valores de consumo de los 172 sensores, además de la columna “*Time*” con la marca temporal a la que corresponde la medición de cada fila. El conjunto de datos incluye 46.608 filas, a intervalos de 15 minutos. Así pues, los datos están organizados por fecha y hora, y cubren el período entre el 05-05-2022 y el 02-09-2023. Algunos sensores (columnas) tienen entradas faltantes (Monteiro, y otros, Electricity consumption dataset of a local energy cooperative, 2024).

Como primer paso se decidió agrupar los valores de los sensores para obtener una serie temporal representativa denominada “**total_consumption**”, que concentraba el consumo global de la comunidad. Esta decisión simplificó el problema, redujo la complejidad inicial y permitió centrar los esfuerzos en la detección de patrones generales sobre esta serie. Lo que se consiguió mediante la siguiente instrucción.

```
df_consumptions_15m['total_consumption'] = df_consumptions_15m.filter(regex='^Energy_Meter_').sum(axis=1, min_count=1)
```

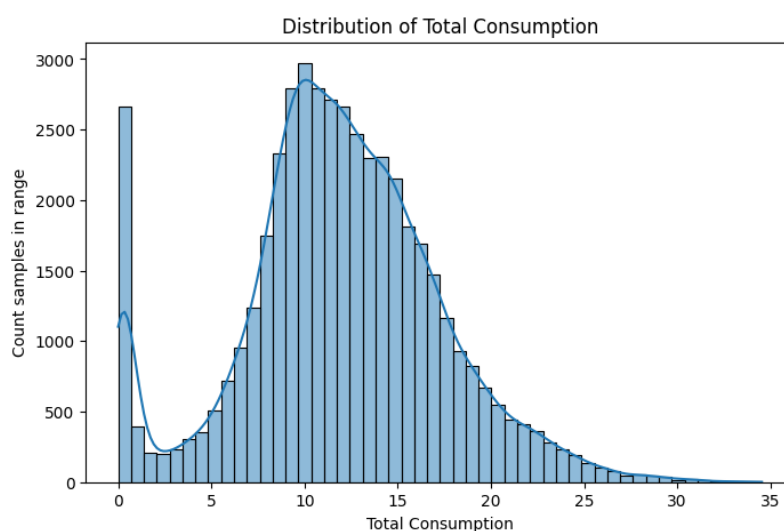
En los siguientes gráficos puede observarse la evolución de la serie *total_consumption*, analizada desde distintas perspectivas. En primer lugar, se presenta la evolución temporal completa de los valores de consumo registrados a intervalos de 15 minutos, lo que permite identificar patrones generales y posibles anomalías en el periodo estudiado. Posteriormente, se muestra el consumo medio diario, que suaviza las variaciones puntuales y facilita la detección de tendencias a lo largo de los meses. Finalmente, se incluye el perfil promedio de consumo diario, calculado con resolución de 15 minutos, el cual permite identificar las franjas horarias de mayor y menor demanda energética.



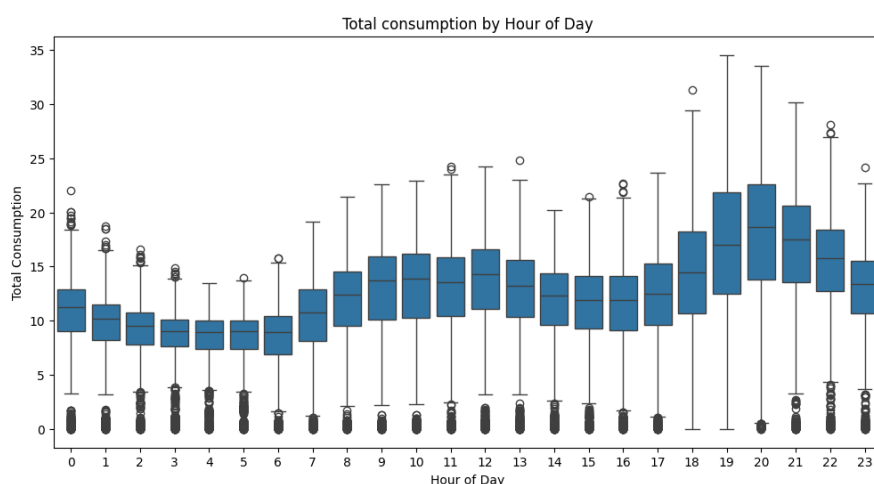
En esta etapa se llevó a cabo un EDA (Exploratory Data Analysis) con el objetivo de comprender en profundidad el comportamiento de la serie temporal de consumo energético. El análisis

incluyó la inspección de la distribución de los datos, la identificación de valores atípicos y patrones recurrentes, así como la verificación de la frecuencia de muestreo (15 minutos) y la detección de periodos con registros incompletos o de baja calidad. Estas tareas permitieron evaluar la variabilidad del consumo tanto a lo largo del día como entre diferentes periodos del año, además de comparar comportamientos estacionales.

El histograma muestra que la mayor parte de los consumos se concentran entre 8 y 15 kWh, con una distribución sesgada hacia la derecha. Se observa también un pico significativo en valores cercanos a cero, que corresponde a periodos de consumo muy bajo o a posibles registros incompletos.

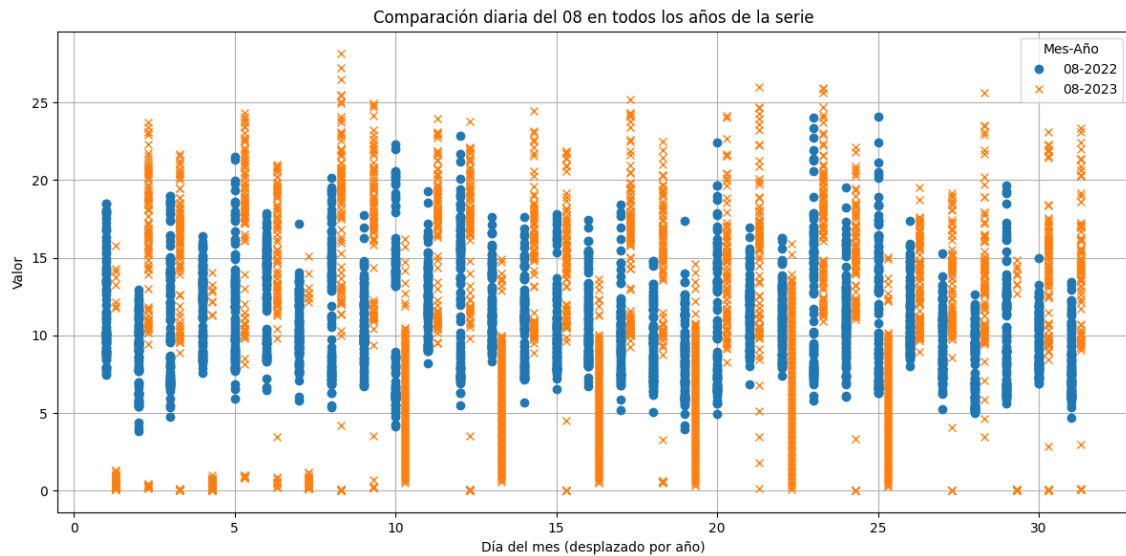


El diagrama de cajas refleja la variabilidad horaria del consumo. Se aprecia un mínimo en las primeras horas de la madrugada (3:00–6:00), seguido de un incremento progresivo durante la mañana. Los picos de mayor consumo se concentran entre las 19:00 y 22:00, lo que coincide con los momentos de mayor actividad residencial. La presencia de outliers indica que en ciertos intervalos se registraron consumos excepcionalmente altos o bajos.



La siguiente gráfica permite contrastar el comportamiento del consumo en el mes de agosto de distintos años. Se observa una gran disparidad de valores en ambos periodos. En 2023 aparecen


registros significativamente más bajos, lo que podría estar relacionado con interrupciones en la serie o mal funcionamiento de los sensores durante ese período. Para la obtención de esta gráfica se definió la función `plot_month_consumption_evolution(serie: pd.Series, month: int)` que facilitó la graficación y estudio de varios meses, tanto en este dataset como en el dataset en el que se estudió la transferibilidad de los modelos.



Así pues, como resultado de este proceso exploratorio, se decidió acotar (mediante la siguiente instrucción Python) el conjunto de datos hasta el 1 de junio de 2023, definiendo así un subconjunto más consistente y representativo, que minimiza sesgos y mejora la fiabilidad en las fases posteriores de entrenamiento y evaluación de modelos predictivos.

```
df_consumptions_15m = df_consumptions_15m[df_consumptions_15m.index < '2023-06-01']
```

La siguiente imagen muestra el perfil medio de 15 minutos antes y después del corte de junio de 2023. Se observa que, aunque la forma del patrón se mantiene, los consumos después del corte son ligeramente más elevados en todas las horas del día, lo que se debe principalmente a la retirada de muchos consumos nulos anómalos.



Además de los datos energéticos, el dataset contiene datos meteorológicos locales relacionados que complementan las mediciones de consumo. Tanto los datos de energía como los meteorológicos fueron recogidos de manera simultánea, con sus respectivas fechas. La

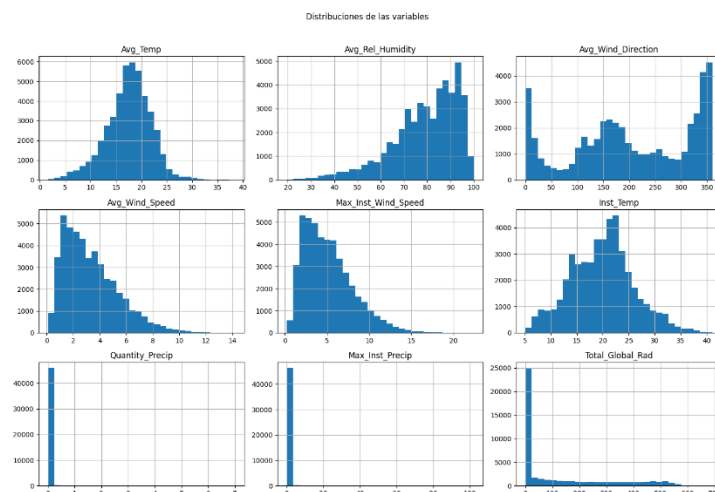
información climática se obtuvo de la estación meteorológica más cercana a Loureiro, ubicada en Aveiro, Portugal (40°38'07.4" N, 8°39'34.6" W).

El archivo CSV con la información climática contiene las siguientes columnas:

- “Time”: fecha y hora de la medición registrada.
- “Avg_Temp”: temperatura media del aire a 1,5 m sobre el suelo, expresada en grados Celsius (°C).
- “Avg_Rel_Humidity”: humedad relativa media, en porcentaje.
- “Avg_Wind_Direction”: dirección del viento, expresada en grados de 0 a 360°.
- “Avg_Wind_Speed”: velocidad media del viento, en m/s.
- “Max_Inst_Wind_Speed”: velocidad máxima instantánea del viento, también en m/s.
- “Inst_Temp”: temperatura instantánea del aire a 1,5 m, en grados Celsius (°C).
- “Quantity_Precip”: cantidad de precipitación en milímetros.
- “Max_Inst_Precip”: intensidad máxima instantánea de precipitación en mm/h.
- “Total_Global_Rad”: radiación global total, medida en KJ/m².

Se llevó a cabo un EDA estándar sobre estas variables, en el que se verificó la ausencia de valores anómalos, aunque se identificaron algunos outliers. No obstante, dado que dichos valores no se consideraron errores de medición, se decidió mantenerlos dentro del conjunto de datos.

La siguiente imagen presenta las distribuciones de las variables meteorológicas incluidas en el análisis. Se observa que la temperatura muestra un comportamiento cercano a la normalidad, mientras que la velocidad del viento y la precipitación presentan distribuciones asimétricas con muchos valores bajos. La humedad relativa tiende a concentrarse en valores altos y la dirección del viento se reparte a lo largo de todo el rango (0–360°).



Etapa 2. Ingeniería de características (feature engineering)

En esta fase se diseñaron nuevas variables con el objetivo de enriquecer la serie de consumo y capturar dependencias temporales o ambientales relevantes. Se distinguieron varios bloques:

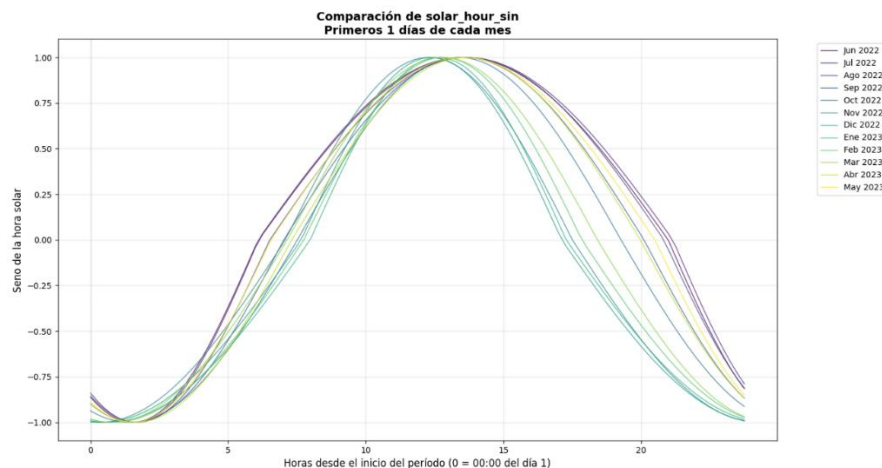
Variables cíclicas horarias.

Siguiendo prácticas habituales en la literatura, se incluyeron transformaciones seno y coseno de la hora (hour_sin, hour_cos) para reflejar el carácter circular del tiempo y facilitar que los modelos aprendieran transiciones suaves entre horas adyacentes.

Variables cíclicas horarias sensibles a la localización geográfica.

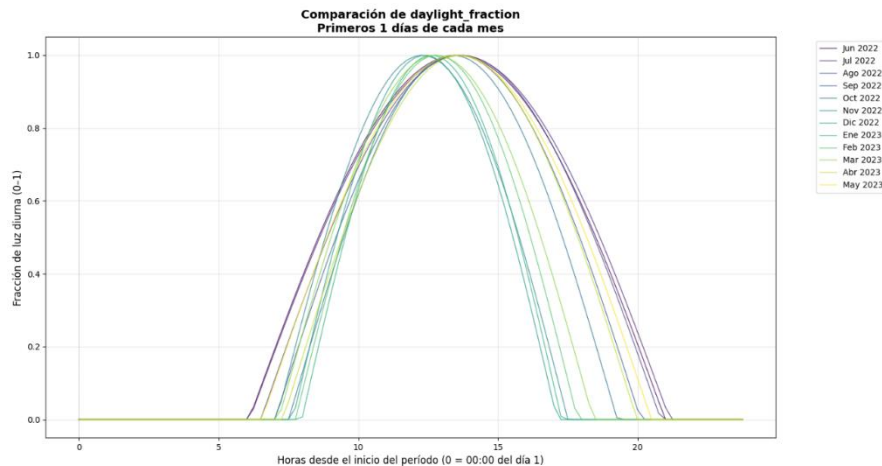
Se diseñaron las variables solar_hour_sin y solar_hour_cos, que redistribuyen los 2π radianes de un día asignando π al intervalo de horas solares y π a las nocturnas, con una proporcionalidad adaptada a la duración del día solar según la localización geográfica (latitud y longitud). Con ello se pretendió capturar la variabilidad de la radiación solar y su efecto en los hábitos de consumo.

La siguiente gráfica muestra la comparación de la variable solar_hour_sin durante el primer día de cada mes. Se aprecia la forma sinusoidal asociada al ciclo diario de la radiación solar, con variaciones en la amplitud y desplazamiento según la época del año, reflejando así los cambios estacionales en la duración del día y la posición del sol.



Fracción de luz solar.

Se creó la variable daylight_fraction, que toma valores entre 0 (noche) y 1 (máximo de radiación solar). Además, se incorporó next_daylight_fraction, concebida para que los modelos pudieran anticipar si la luminosidad iba a crecer o decrecer en el siguiente intervalo. La siguiente gráfica muestra el comportamiento de esta variable.



Estacionalidad semanal.

Para modelar la repetición de patrones semanales, se añadieron `dow_sin` y `dow_cos` (día de la semana).

Días laborales y festivos.

La variable categórica `working_day` se construyó combinando fines de semana y festivos locales de Loureiro, identificados mediante calendarios oficiales.

Valores retardados de consumo.

Inicialmente se incluyeron 10, y luego 20 retardos, pero tras las primeras pruebas se comprobó que esa ventana no bastaba para reflejar los patrones diarios de la demanda. Por ello se ampliaron a 96 retardos (denominados `last_consumption_1` ... `last_consumption_96`), de modo que el modelo dispusiera del ciclo completo previo de 24 horas (un día completo en intervalos de 15 minutos) y pudiera capturar mejor la estacionalidad intradiaria característica del consumo eléctrico.


Lags estacionales diarios.

Para capturar la estacionalidad semanal se añadieron retardos con múltiplos de 96 (1 a 14 días), definidos como `lag_Ndays`. De esta forma, el modelo podía comparar el consumo actual con el de la misma hora en días anteriores.

Etapa 3. Selección de características

Dada la gran cantidad de predictores generados, se implementó un proceso de selección basado en **métodos complementarios**, buscando reducir dimensionalidad y evitar redundancias:

- **Correlación lineal** (coeficiente de Pearson) para identificar dependencias directas con la variable objetivo. Se utilizó el método `corr()` de la clase `DataFrame` de Pandas. La imagen de la siguiente página muestra las ponderaciones obtenidas para estas dependencias.



- **Información mutua**, capaz de detectar relaciones no lineales. Se obtuvo mediante la función `mutual_info_regression(...)` del paquete `sklearn.feature_selection`.
- **Lasso Regression**, que aplica regularización L1 para eliminar variables poco relevantes. Se obtuvo mediante la clase `LassoCV` del paquete `sklearn.linear_model`.
- **Importancia de características en Random Forest (MDI)**, que mide la reducción de impureza acumulada. Se obtuvo mediante el atributo `feature_importances_` de un modelo Random Forest entrenado con todas las características.
- **Permutation Importance (MDA)**, considerada más robusta al medir el impacto real de cada variable sobre el rendimiento del modelo entrenado. Se obtuvo mediante la función `permutation_importance` del paquete `sklearn.inspection` usando el modelo Random Forest entrenado anteriormente.

Con los resultados se elaboraron tres niveles de relevancia:

- **Tier 1 (obligatorias)**: aquellas variables confirmadas por el método más sólido (MDA) y, además, por cualquiera de los otros. Resultaron 49 variables.
- **Tier 2 (candidatas)**: variables que no estén en Tier1 y se encuentran referidas en al menos dos métodos. 62 variables.
- **Tier 3 (descartables)**: el resto de variables. Predictores que no mostraban impacto significativo o eran redundantes. 17 variables.

La combinación de estos enfoques permitió construir un consenso robusto, siguiendo las recomendaciones encontradas en revisiones sistemáticas recientes.

A continuación se muestran las 49 variables del conjunto Tier1, mostrándose resaltadas aquellas que son exógenas a la serie temporal:

```
['Inst_Temp', 'last_consumption_96', 'solar_hour_cos', 'lag_7days', 'last_consumption_92', 'last_consumption_1',
'last_consumption_94', 'last_consumption_40', 'lag_1days', 'last_consumption_93', 'last_consumption_90',
'last_consumption_88', 'last_consumption_3', 'last_consumption_11', 'last_consumption_43', 'last_consumption_6',
'last_consumption_5', 'last_consumption_23', 'last_consumption_89', 'last_consumption_44', 'last_consumption_84',
'last_consumption_8', 'last_consumption_20', 'last_consumption_2', 'last_consumption_19', 'hour_sin',
'last_consumption_86', 'last_consumption_29', 'last_consumption_91', 'last_consumption_7', 'last_consumption_28',
'last_consumption_14', 'last_consumption_22', 'solar_hour_sin', 'hour_cos', 'Total_Global_Rad',
'last_consumption_38', 'last_consumption_37', 'last_consumption_34', 'last_consumption_80', 'last_consumption_50',
'last_consumption_64', 'last_consumption_83', 'daylight_fraction', 'dow_sin', 'last_consumption_46',
'last_consumption_39', 'next_daylight_fraction', 'last_consumption_69']
```

Etapa 4. Modelado y entrenamiento

Se adoptó una estrategia incremental de modelado. La comparación de modelos se basó en métricas estándar R^2 , RMSE y MAPE, manteniendo la coherencia con los trabajos más citados en el área. La medición del coste computación se realizó someramente usando la “instrucción

mágica” %time que ofrece Google Colab, y que mide el tiempo de CPU y el tiempo de “reloj de pared” consumido en la ejecución de una instrucción.

1. Modelos de referencia:

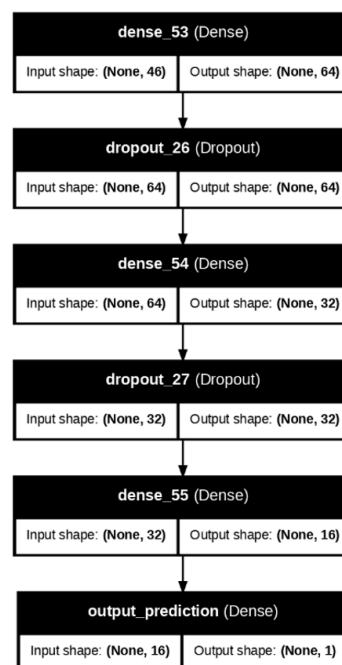
- *SARIMAX*, modelo estadístico clásico, aportó una base comparativa con técnicas tradicionales.
- *Random Forest*, elegido por su rapidez y facilidad de configuración, permitió realizar evaluaciones preliminares con un bajo coste computacional. Consiguió los mejores resultados sobre el resto de modelos, con un $R^2=0,9568$, usando las variables etiquetadas como Tier1.

- ### 2. Redes neuronales densas:
- implementadas como baseline de *deep learning* sin arquitectura específica para series temporales. Logró un modesto $R^2=0,8781$ con un bajo coste computacional, aunque algo mayor que Random Forest. Posteriormente, se implementó un modelo ensamblado de varias redes densas por franjas horarias que alcanzó un $R^2=0,8933$.

Model: "DENSE"

Layer (type)	Output Shape	Param #
dense_53 (Dense)	(None, 64)	3,008
dropout_26 (Dropout)	(None, 64)	0
dense_54 (Dense)	(None, 32)	2,080
dropout_27 (Dropout)	(None, 32)	0
dense_55 (Dense)	(None, 16)	528
output_prediction (Dense)	(None, 1)	17

Total params: 5,633 (22.00 KB)
Trainable params: 5,633 (22.00 KB)
Non-trainable params: 0 (0.00 B)



- ### 3. Redes neuronales recurrentes (LSTM):
- ampliamente utilizadas en forecasting energético, se entrenaron con diferentes conjuntos de variables, observando los resultados a través de las métricas MAPE, RMSE y R^2 .

Se comenzó preparando un dataset con la función `timeseries_dataset_from_array` del paquete `keras.utils`, con una longitud de secuencia (`sequence_length`) de 96 muestras. Ante los pobres resultados obtenidos y buscando permitir a la red neuronal que observara la estacionalidad semanal, se aumentó la ventana a 1.344 muestras (14 días x 96 muestras/día), con lo que se logró un $R^2=0,9151$. Luego se logró mejorar hasta

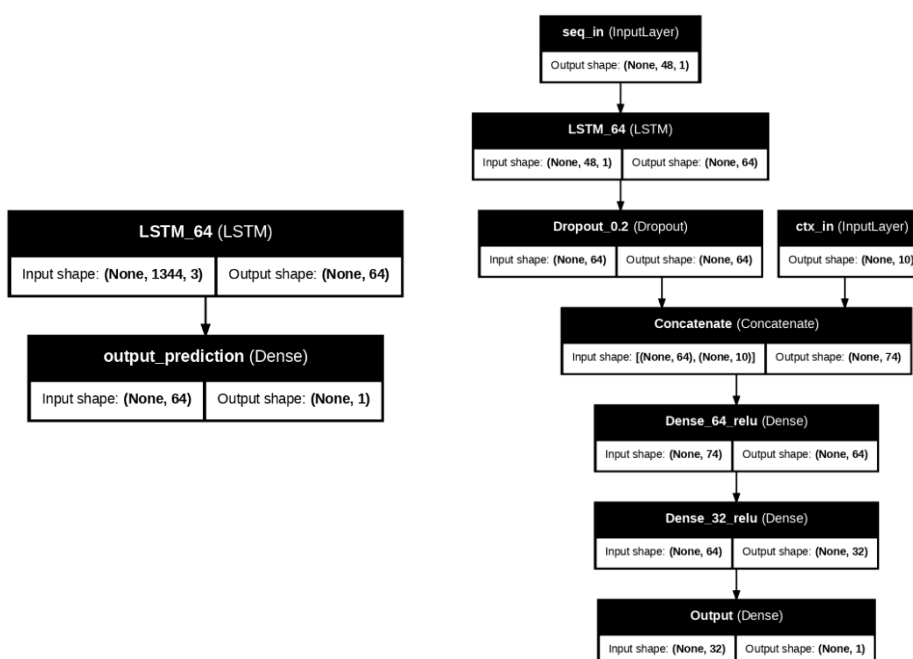
R2=0,9174 añadiendo las series de hora solar (solar_hour_sin y solar_hou_cos), comprobándose que superaba los resultados obtenidos con la hora cíclica simple.

Sin embargo, al entrenar el modelo LSTM añadiendo Inst_temp a la serie principal y las series de hora solar, en vez de mejorar los resultados como parecía indicar la clasificación Tier1, los resultados empeoraron desde R2=0,9174 a R2=0,7103.

Model: "LSTM_series_ctxt"

Layer (type)	Output Shape	Param #
LSTM_64 (LSTM)	(None, 64)	17,408
output_prediction (Dense)	(None, 1)	65

Total params: 17,473 (68.25 KB)
Trainable params: 17,473 (68.25 KB)



4. **Redes neuronales convolucionales temporales (TCN):** exploradas como alternativas más precisas que las LSTM, aprovechando su capacidad de procesar secuencias largas mediante convoluciones dilatadas y residual connections. Tras varias pruebas infructuosas, cuyos entrenamientos resultaron excesivamente lentos, se descartaron, pues implicaban un coste computacional mucho mayor que LSTM y, con más diferencia aún, que Random Forest, aunque se obtuvieron rendimientos realmente buenos (R2=0,9138).

Etapa 5. Transferibilidad y validación cruzada


Finalmente, se abordó la capacidad de transferir el conocimiento adquirido por un modelo entrenado con el dataset de Loureiro a otra comunidad energética. Para ello, se seleccionó un dataset de Londres que fue sometido a un EDA y adaptado para generar las mismas variables empleadas en Loureiro.


Para ello se realizó la operación que se precisa en el siguiente trozo de código Python, en la que se lleva a cabo una interpolación de la serie temporal de consumos. En primer lugar, se ordenaron los registros y se agregaron los valores de energía (KWH) correspondientes a cada

instante de tiempo, sumando así los consumos de los diferentes contadores (LCLiDs). Posteriormente, la serie se re-muestreó a intervalos regulares de 15 minutos, lo que generó algunos valores nulos en los huecos sin datos. Finalmente, dichos huecos internos se completaron mediante una interpolación temporal suave, garantizando la coherencia de la señal y obteniendo una columna consolidada denominada `total_consumption`.

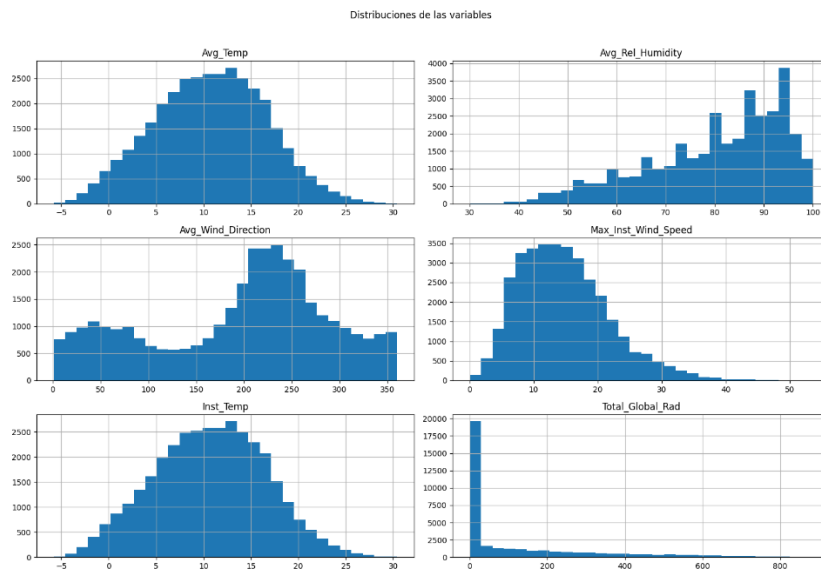
```
df_london_consumptions_15m = (  
    df_london_consumptions  
    .sort_index()  
    .groupby(level=0)["KWH"].sum() # sumar KWH para timestamps duplicados (hay varios LCLid por timestamp)  
    .resample("15min").asfreq() # Filas cada 15 minutos. Algunas pueden tener NaN  
    .interpolate(method="time",  
                limit_direction="both",  
                limit_area="inside") # interpolación suave sólo en huecos internos  
    .to_frame(name="total_consumption")  
)
```

Tras esa operación se observa que el perfil de consumo energético de la comunidad de Londres mantiene una cierta tendencia parecida a la comunidad de Loureiro, aunque con ciertas diferencias, principalmente de magnitud.





Para los datos meteorológicos se consumió la API [Open-Meteo Archive](#), especificando en la petición las coordenadas de latitud y longitud de la zona de estudio, así como las variables horarias de interés. Además, se delimitaron las fechas de inicio y fin del intervalo a analizar, y se configuró la zona horaria correspondiente a *Europe/London*. De esta manera, se obtuvieron series meteorológicas coherentes y alineadas temporalmente con los datos de consumo eléctrico previamente procesados. Posteriormente, fue necesario realizar una interpolación para obtener una frecuencia de 15 minutos, como la del dataset Loureiro.



Finalmente, se realizó el mismo proceso de “feature engineering” para este dataset. De esta forma se obtuvieron todas las variables necesarias para poder estudiar la transferibilidad de los modelos anteriormente entrenados.

Dado que el entrenamiento de cada modelo implicaba un tiempo considerable, el procedimiento se dividió en distintas sesiones de trabajo. Para garantizar la continuidad del estudio, en cada sesión se guardaron tanto los modelos entrenados como sus respectivos escaladores, lo que permitió retomar el análisis sin necesidad de repetir los costosos procesos de entrenamiento y prueba.

Los primeros ensayos de transferencia no fueron satisfactorios, lo que llevó a explorar dos vías:

- Transfer learning profundo con fine-tuning, estrategia que ha mostrado gran potencial en forecasting energético.
- Transformación de la serie en deltas (diferencias entre valores consecutivos), con el objetivo de reducir sesgos de escala. Sin embargo, los resultados no fueron concluyentes debido al ruido intrínseco de las series de incrementos, como ya se ha reportado en la literatura.

Posteriormente se revisaron los procesos de imputación de valores faltantes. Inicialmente se habían completado mediante medianas horarias globales, pero al sustituir este procedimiento por una interpolación lineal entre valores adyacentes se obtuvo una mejora en la coherencia de las predicciones.

6. EVALUACIÓN

Se pueden distinguir tres procesos de evaluación en este Global Project: (1) para la selección de las características más significativas, (2) tras el entrenamiento de los modelos para la verificación su rendimiento, y (3) para la comprobación de la transferibilidad de los modelos ya entrenados a nuevos conjuntos de datos de otras comunidades energéticas.

6.1. Evaluación en la selección de características

El método de selección de variables a partir de la combinación de varios enfoques (correlación lineal, información mutua, Lasso, Random Forest, importancia por permutación, etc.) se fundamenta en la necesidad de reducir la dependencia de un único criterio que, de manera aislada, podría introducir sesgos o limitaciones en el modelo.

Cada técnica de selección aporta una perspectiva distinta: la **correlación** identifica relaciones lineales simples, pero no controla multicolinealidad; la **información mutua** detecta relaciones no lineales, aunque puede ser sensible al ruido; **Lasso** penaliza coeficientes y ayuda a eliminar redundancias, pero depende de la regularización; los **bosques aleatorios** ofrecen una medida robusta de importancia basada en ensambles, aunque tienden a favorecer variables con más categorías; y la **importancia por permutación** (MDA) mide directamente el impacto de cada variable en el rendimiento del modelo, siendo uno de los indicadores más fiables.

Integrar todos estos métodos permite construir un consenso que refuerza la robustez de la selección final, ya que si una variable aparece de forma consistente en varios enfoques independientes es más probable que realmente tenga un papel relevante en la predicción.

Además, dar un mayor peso a los métodos que evalúan el efecto sobre el modelo entrenado (RF, MDA) asegura que las decisiones se fundamenten en evidencia empírica del impacto real en el desempeño, mientras que mantener un nivel intermedio de consideración a técnicas como Lasso o información mutua ayuda a captar relaciones complejas o a controlar redundancias.

Aunar estas ponderaciones en un único criterio de clasificación en diferentes niveles (obligatorias, candidatas, descartables) aporta una estrategia práctica para la toma de decisiones: las obligatorias son aquellas cuya relevancia se confirma en los métodos más sólidos, las candidatas se mantienen como opciones a validar en fases posteriores de experimentación, y las descartables se eliminan para simplificar el modelo y evitar sobreajuste. Finalmente, validar mediante validación cruzada distintos subconjuntos de variables garantiza que la selección no sea solo teórica, sino que se confirme en términos de rendimiento predictivo, alcanzando un equilibrio entre simplicidad, interpretabilidad y capacidad de generalización del modelo.

Sin embargo, para modelos neuronales como LSTM o TCN se ha optado por seguir un enfoque progresivo de selección de variables, comenzando con un entrenamiento basado únicamente en la propia serie temporal a predecir y, posteriormente, incorporando de manera gradual distintas características adicionales para evaluar su impacto en el rendimiento del modelo. Esta estrategia ha permitido observar cómo cada variable influye en la capacidad predictiva, evitando

la inclusión indiscriminada de información irrelevante o redundante. No obstante, el proceso no ha podido ser exhaustivo debido tanto a las limitaciones inherentes a la envergadura del proyecto como a las restricciones de capacidad de cómputo disponibles, lo que ha obligado a priorizar experimentos más acotados en lugar de una exploración completa del espacio de características posibles.

6.2. Evaluación del rendimiento de los modelos

La evaluación del rendimiento de los modelos atiende a uno de los principales objetivos de este proyecto: la predicción un paso por delante ($t+1$), con resolución de 15 minutos, del consumo de la comunidad energética. Para ello, en todos los modelos entrenados se compara la predicción frente al valor real sobre un conjunto de test reservado cronológicamente o por selección aleatoria, dependiendo del modelo.

Para el cálculo de las métricas comunes, se unificó el proceso en la función `print_metrics(y_true, y_pred, model_name)`, la cual se encarga de generar y mostrar los resultados, los cuales son:

- MSE, error cuadrático medio.
- RMSE, raíz del MSE, en las unidades originales de consumo.
- MAPE, error porcentual absoluto medio. Para robustez numérica se divide por 10^{-8} para evitar divisiones por cero.
- R^2 , coeficiente de determinación.

Además de las métricas numéricas, se ha empleado también análisis visual por subgrupos temporales. Así, se ha conseguido observar detalladamente el ajuste de los resultados obtenidos por los modelos. A continuación se relacionan las funciones creadas para este fin.

- `plot_r2_by_hour(...)`: R^2 por hora del día (agregando por `index.hour`).
- `plot_r2_by_day_of_week(...)`: R^2 por día de la semana (0=Lunes...6=Domingo).
- `plot_predictions_vs_actual(...)`: dispersograma real vs predicho con línea $y=xy=x$.
- En algunos bloques también se dibujan series temporales (real vs predicción) para inspección visual de desvíos.

Con esto, no solo se cuantifica el ajuste global, sino que se detectan patrones de error dependientes de la hora/día (p. ej., degradación típica en cambios de régimen o transiciones mañana-tarde).

En cuanto a la selección de las muestras de entrenamiento, validación y evaluación, se pueden apreciar las siguientes aproximaciones dependiendo del modelo:

Random Forest y red neuronal densa simple

Se partitionaron los datos aleatoriamente mediante la función `train_test_split`, tomando el 80% para entrenamiento y el 20% para evaluación. Además, el conjunto de entrenamiento se barajó antes de utilizarlo.

Red neuronal densa por franjas horarias (ensamblado)

El conjunto de datos se divide en 64% para entrenamiento, 16% para validación y 20% para prueba. A continuación, se entrena un modelo independiente para cada franja horaria utilizando únicamente las muestras correspondientes a esa franja. Finalmente, en la etapa de prueba se ensambla el resultado aplicando el modelo que corresponda según la hora de cada muestra, evaluando el coeficiente de determinación (R^2) tanto por franja como de manera global.

Redes secuenciales (LSTM/TCN)

A diferencia de los enfoques anteriores, la partición del conjunto de datos se realizó de manera cronológica, reservando el 80% de las muestras iniciales para entrenamiento, un 10% adicional dentro de este bloque para validación, y el 20% restante para la fase de evaluación. Con ello se evita la fuga de información entre conjuntos y se reproduce un escenario más realista en el que los modelos aprenden sobre el pasado para anticipar el futuro.

6.3. Evaluación de la transferibilidad de los modelos

Para lograr la evaluación de transferibilidad para cada modelo se han utilizado las mismas métricas que en el apartado anterior (MSE, RMSE, MAPE y R^2). Esto ha permitido mantener la coherencia en el análisis y realizar una comparación homogénea del rendimiento de los modelos entre la comunidad de referencia y la nueva comunidad energética, facilitando así la identificación de pérdidas o mejoras en la capacidad predictiva al cambiar de dominio.

Por otro lado, la evaluación de los modelos, para este caso, se ha realizado sobre toda la serie disponible de la nueva comunidad energética, de tal forma que se obtiene una visión integral del comportamiento predictivo en distintos contextos temporales (variaciones diarias, semanales y estacionales), evitando sesgos derivados de una partición arbitraria de los datos. Este enfoque permite valorar con mayor fidelidad la capacidad de generalización del modelo cuando se enfrenta a dinámicas de consumo distintas a las observadas en su entrenamiento original.

Además de las métricas numéricas, también se han analizado representaciones gráficas para comparar los perfiles medios de consumo diarios entre la comunidad de Loureiro, la comunidad de Londres y la predicción obtenida mediante el modelo.

Así, los resultados de esta evaluación de transferibilidad permiten cuantificar hasta qué punto los modelos entrenados en una comunidad energética mantienen su utilidad en otro entorno. También proporcionan información clave para decidir si es suficiente aplicar los modelos directamente o si es necesario realizar procesos adicionales de ajuste fino (fine-tuning) o reentrenamiento parcial.

7. RESULTADOS

En este apartado se presentan los resultados obtenidos a partir del proceso de evaluación de la solución propuesta. Los datos se exponen siguiendo una notación científica estándar, con el fin de garantizar claridad, precisión y coherencia en la interpretación.

En primer lugar, se presentan los resultados del proceso de selección y clasificación de variables, cuyo objetivo fue identificar aquellas características con mayor capacidad explicativa en la predicción de la demanda eléctrica. Para ello, se organizaron las variables en tres niveles jerárquicos (Tiers), diferenciando entre las obligatorias, las candidatas y las descartadas. Esta estructuración permitió no solo analizar el peso relativo de los retardos autorregresivos del consumo, sino también evaluar el valor añadido de variables exógenas de carácter climático y temporal, siguiendo la práctica recomendada en la literatura científica sobre forecasting energético.

En **Tier 1** se incluyeron las variables obligatorias, dominadas por los retardos horarios de consumo eléctrico (last_consumption_N), que constituyen la base autorregresiva del modelo y permiten capturar la estacionalidad intradía. Junto a ellas, se mantuvo un bloque reducido de variables exógenas —temperatura instantánea, radiación global, fracción de luz solar, hora solar en forma trigonométrica, día de la semana y retardos agregados como lag_1days y lag_7days— que aportan información contextual. La presencia de este conjunto confirma que la dinámica del consumo no depende únicamente de la autocorrelación, sino también de la influencia del entorno climático y social, en línea con lo observado en la literatura reciente.


En **Tier 2** se agruparon las candidatas, donde aparecen retardos adicionales de mayor distancia temporal (lags de 2 a 14 días) y variables meteorológicas promedio (temperatura media, humedad relativa, viento y precipitación acumulada). Estas características pueden capturar dependencias semanales o fenómenos climáticos más prolongados, pero su aporte marginal resulta menor y, en muchos casos, condicionado a situaciones específicas (olas de calor, cambios estacionales o eventos de precipitación). Así, se identifican como variables útiles para enriquecer los modelos en escenarios concretos, aunque no siempre garanticen una mejora estable de la precisión.

En **Tier 3** quedaron las variables descartadas, en su mayoría retardos horarios redundantes que no añadían información relevante frente a los ya seleccionados, junto con un único exógeno —la precipitación máxima instantánea— que mostró escasa capacidad explicativa. Este resultado refuerza la necesidad de evitar indicadores climáticos demasiado puntuales, cuya relación con la demanda es débil o ruidosa, como ya han señalado revisiones sistemáticas previas.

Las variables externas a la serie de consumos de los tiers fueron:

- Tier1: 'Inst_Temp', 'solar_hour_cos', 'hour_sin', 'Total_Global_Rad', 'solar_hour_sin', 'hour_cos', 'daylight_fraction', 'dow_sin' y 'next_daylight_fraction'.
- Tier2: 'Max_Inst_Wind_Speed', 'Avg_Temp', 'Quantity_Precip', 'Avg_Wind_Direction', 'working_day', 'Avg_Rel_Humidity', 'dow_cos' y 'Avg_Wind_Speed'.
- Tier3: 'Max_Inst_Precip'.

En conjunto, la organización jerárquica confirma que un núcleo reducido de retardos autorregresivos cercanos, combinado con un grupo de variables exógenas que representan tanto condiciones climáticas como factores temporales, constituye la base más sólida para la predicción. A partir de ahí, los retardos más largos y las variables agregadas pueden incorporarse de manera selectiva, según el modelo y el contexto de aplicación. De esta manera, se logra un equilibrio entre robustez, capacidad predictiva y coste computacional, alineado con las recomendaciones actuales en el ámbito del forecasting energético.



Otro resultado de este Global Project es el relacionado con el **análisis de los modelos aplicables para el dataset de estudio**. En la siguiente tabla se presentan los valores del coeficiente de determinación (R^2) obtenidos para los distintos modelos evaluados. Se observa que los algoritmos basados en **Random Forest** alcanzan los mejores desempeños, destacando el modelo construido con las variables del Tier 1 ($R^2 = 0,9568$), ligeramente por encima de su versión ampliada con variables del Tier 2. Los **modelos densos** (DenseNN) muestran un rendimiento inferior, con resultados que decrecen al incorporar más variables, aunque los ensambles mejoran parcialmente la capacidad predictiva respecto a las redes densas simples. En cuanto a los modelos secuenciales, se aprecia que las redes **LSTM** logran valores de R^2 próximos a **0,92** en varias configuraciones, confirmando su idoneidad para la predicción de series temporales, mientras que la inclusión de ciertas variables de contexto (por ejemplo, día laborable o temperatura instantánea) puede deteriorar gravemente el ajuste. Finalmente, se evidencia que las redes convolucionales temporales (**TCN**) alcanzan un rendimiento comparable al de las LSTM, situándose también en torno a **0,91** de R^2 . En conjunto, se concluye que el modelo Random Forest con Tier 1 constituye la mejor alternativa dentro de los experimentos realizados, al combinar simplicidad y elevada capacidad explicativa, en línea con lo reportado en la literatura sobre predicción de demanda energética.

Modelo	R2
SAMIRAX 14 días	0,9196
Random Forest Tier1	0,9568
Random Forest Tier1 + Tier2	0,9567
Random Forest Tier2	0,9185
DenseNN Tier1	0,8781
DenseNN Tier1 + Tier2	0,8587
DenseNN Tier2	0,7938
DenseNN Ensamble1	0,8933
DenseNN Ensamble2	0,89
LSTM Tier1 window 20	0,8929
LSTM 14días y series hora solar cíclica	0,9174
LSTM 14 días y series hora "simple" cíclica	0,9148
LSTM 14 días y contexto simple hora solar	0,9128
LSTM 14 días y series hora solar cíclica y Inst.Temp.	0,7103
LSTM 14 días y series hora solar cíclica y working day	-1,6706
LSTM 14 días y series hora solar cíclica y DOW cíclico	0,9182
TCN y series hora solar cíclica	0,9138
TCN y series hora solar cíclica y Int.Temp.	0,8886




Un aspecto especialmente relevante se observa en la comparación entre las series construidas con la hora “solar” y las que emplean la hora “simple”. La utilización de **la hora “solar”, codificada de manera cíclica, proporciona de forma consistente un mejor desempeño predictivo que la hora simple**, con incrementos de R^2 que refuerzan su utilidad práctica. **Este resultado constituye un avance significativo respecto a la literatura revisada**, al mostrar que la incorporación de la variación solar debida a la posición geográfica mediante la hora solar no requiere un coste computacional elevado y, sin embargo, aporta mejoras claras en la capacidad explicativa del modelo. Puede considerarse, por tanto, un hallazgo innovador dentro del ámbito de la predicción de demanda energética, pues introduce una característica sencilla y robusta que complementa y mejora los enfoques previamente reportados

Respecto al objetivo de medir la transferibilidad de los modelos a una serie de consumos diferente a la que se usó para entrenamiento, en una localización geográfica diferente, se muestra a continuación la representación gráfica

Para el estudio de transferibilidad se seleccionaron los modelos con mejor desempeño dentro de cada categoría de algoritmos: Random Forest como representante de los modelos base o tradicionales, DenseNN para redes neuronales densas y LSTM para arquitecturas recurrentes profundas. Estos tres modelos fueron entrenados con los consumos de la comunidad energética de Loureiro y posteriormente aplicados sin reentrenamiento sobre la serie de consumos de Londres, a fin de evaluar su capacidad de generalización.


En las figuras incluidas, se muestran en línea continua los patrones de consumos medios diarios reales de Loureiro y de Londres, junto a la predicción generada por cada modelo representada por una línea punteada. La comparación visual permite apreciar con claridad el grado de

acoplamiento entre las curvas, evidenciando en qué medida cada modelo logró adaptarse al nuevo contexto de aplicación desde su contexto de entrenamiento.



Los resultados cuantitativos ponen de manifiesto comportamientos diferenciados en la transferibilidad de los modelos. El **Random Forest**, que había alcanzado un R^2 de 0,9568 en Loureiro, mantuvo un desempeño notable con un **R^2 de 0,8506 en Londres**. Pese a la pérdida de precisión, se confirma que los métodos de ensamble basados en árboles pueden conservar parte sustancial de su capacidad predictiva en dominios distintos. Por el contrario, el **DenseNN**, que

en Loureiro obtuvo un R^2 de 0,8781, mostró una fuerte caída en la transferibilidad, alcanzando apenas **R^2 de 0,6719 en Londres**. Esto sugiere que los modelos densos, al no estar diseñados para capturar dependencias temporales prolongadas, tienden a sobre ajustarse al patrón local de entrenamiento y resultan menos robustos en entornos diferentes. Finalmente, el **LSTM** demostró la mayor capacidad de generalización: de un R^2 de 0,9182 en Loureiro pasó a **R^2 de 0,8841 en Londres**, manteniendo un nivel de precisión muy próximo al obtenido con el dataset original, y confirmando la idoneidad de las arquitecturas recurrentes para capturar patrones transferibles de consumo eléctrico.



En conjunto, la evidencia permite reflexionar sobre la importancia de la arquitectura en la capacidad de transferir modelos entre distintas comunidades energéticas. Mientras que las redes densas muestran limitaciones severas, los Random Forest mantienen un rendimiento aceptable y las **LSTM alcanzan un desempeño sobresaliente**, lo que coincide con la literatura reciente en transferencia de modelos de predicción de demanda eléctrica. Estos hallazgos sugieren que las arquitecturas recurrentes deben considerarse como candidatas prioritarias en escenarios donde se requiera aplicar modelos entrenados en un contexto geográfico a otro distinto, favoreciendo la escalabilidad y reutilización de sistemas predictivos en el marco de las smart grids

8. CONCLUSIONES Y TRABAJOS FUTUROS

Los resultados obtenidos en este trabajo permiten extraer varias conclusiones relevantes en relación con los objetivos planteados. En primer lugar, el proceso de selección y clasificación de variables en tres niveles jerárquicos (Tiers) ha demostrado ser una estrategia eficaz para identificar aquellas características con mayor capacidad explicativa en la predicción de la demanda eléctrica. Se ha confirmado que los retardos autorregresivos de consumo a corto plazo, combinados con un grupo reducido de variables exógenas de naturaleza temporal y climática, constituyen una base sólida para la predicción. Este hallazgo refuerza lo señalado por estudios previos, donde se destaca la importancia de combinar autocorrelaciones con factores externos para mejorar la precisión de los modelos de forecasting energético.

En relación con los modelos predictivos, los resultados cuantitativos y cualitativos muestran que los algoritmos de ensamble basados en árboles, particularmente Random Forest, alcanzan el mejor desempeño dentro de los experimentos realizados. En concreto, el Random Forest entrenado con las variables del Tier 1 obtuvo un R^2 de 0,9568, superando modelos del mismo tipo entrenados con más variables y evidenciando que un conjunto reducido y bien seleccionado de características puede ser más eficiente que configuraciones más complejas.

Por su parte, las redes neuronales densas presentaron limitaciones significativas, especialmente cuando se incrementó el número de variables, mientras que las redes LSTM y TCN confirmaron su idoneidad para la predicción de series temporales al alcanzar valores de R^2 en torno a 0,91. Estos resultados concuerdan con investigaciones recientes que destacan la superioridad de arquitecturas recurrentes y convolucionales frente a modelos densos en tareas de predicción energética.

Un aspecto innovador del presente trabajo es la constatación del valor predictivo de la hora solar frente a la hora simple. La inclusión de la hora solar en codificación cíclica ha mostrado mejoras sistemáticas en la precisión de los modelos, constituyendo un aporte novedoso respecto a la literatura revisada. Este hallazgo demuestra que es posible introducir mejoras sustanciales en la capacidad explicativa mediante la incorporación de variables derivadas de la posición solar, sin necesidad de incrementar de manera significativa los costes computacionales.

En cuanto a la transferibilidad de los modelos, los resultados evidencian comportamientos diferenciados según la arquitectura utilizada. Random Forest mostró una capacidad moderada de generalización al mantener un R^2 de 0,8506 en el dataset de Londres, mientras que las redes densas evidenciaron una pérdida severa de precisión, lo que confirma su tendencia al sobreajuste a patrones locales. Por el contrario, las LSTM demostraron la mayor capacidad de generalización, manteniendo un R^2 de 0,8841 en Londres tras haber alcanzado 0,9182 en Loureiro. Esto confirma que las arquitecturas recurrentes ofrecen una mayor robustez y escalabilidad en escenarios donde se requiere transferir modelos entre comunidades energéticas diferentes, lo que constituye un avance significativo para el despliegue de soluciones predictivas en smart grids.

En conjunto, se puede concluir que los objetivos establecidos al inicio del proyecto se han alcanzado satisfactoriamente: (i) se han identificado las variables con mayor impacto en la predicción de la demanda, (ii) se han evaluado diferentes arquitecturas y algoritmos, destacando la efectividad del Random Forest y las LSTM, (iii) se ha introducido una innovación metodológica con la hora solar, y (iv) se ha validado la capacidad de transferencia de modelos entre comunidades energéticas, un aspecto clave para la escalabilidad de soluciones en el marco de las redes inteligentes.

No obstante, este trabajo también presenta limitaciones. En particular, la selección de variables no pudo ser exhaustiva debido a restricciones computacionales, lo que impidió evaluar la totalidad de combinaciones posibles de retardos y variables exógenas. Además, el análisis de transferibilidad se circunscribió a dos comunidades energéticas, por lo que sería necesario ampliar el estudio a un número mayor de contextos geográficos y sociales para consolidar las conclusiones.

De cara a futuros trabajos, se identifican varias líneas de investigación:

1. **Ampliación de la transferibilidad:** aplicar la metodología a diferentes comunidades energéticas en distintos países, explorando la robustez de los modelos frente a heterogeneidades en los patrones de consumo.
2. **Modelos híbridos y de aprendizaje por transferencia:** incorporar técnicas de *deep transfer learning* como las planteadas en la literatura reciente, que podrían mejorar aún más la precisión y reducir la necesidad de grandes volúmenes de datos de entrenamiento en el dominio objetivo.
3. **Integración con sistemas SCADA:** desarrollar pruebas de despliegue de los modelos en entornos de control en tiempo real, para evaluar su aplicabilidad práctica en la gestión de comunidades energéticas.
4. **Variables de comportamiento social:** explorar la incorporación de indicadores adicionales relacionados con hábitos de consumo colectivos, teletrabajo o movilidad eléctrica, cuya relevancia se está consolidando en los últimos estudios internacionales.
5. **Optimización computacional:** avanzar hacia arquitecturas más eficientes, capaces de entrenar modelos complejos reduciendo tiempos y costes, lo que favorecería su aplicabilidad en contextos industriales.

En definitiva, los resultados obtenidos no solo validan la importancia de la selección adecuada de variables y modelos para la predicción de la demanda eléctrica, sino que también abren nuevas oportunidades de investigación e innovación. El trabajo contribuye así al desarrollo de soluciones predictivas más precisas, transferibles y escalables, alineadas con los objetivos globales de transición energética y despliegue de smart grids sostenibles.

9. REFERENCIAS

- F. Torres, J., Martínez-Álvarez, F., & A., T. (2021). A Deep LSTM Network for the Spanish Electricity Consumption Forecasting. *Neural Computing and Applications, Springer*, 3059–3078.
- Fang, X., Misra, S., Xue, G., & Yang, D. (2012). Smart Grid — The New and Improved Power Grid: A Survey. *IEEE*, 944–980.
- FutuRed & Boston Consulting Group. (2012). *Desarrollo de las redes eléctricas inteligentes (smart grids) en España*. Madrid, España: FutuRed.
- Grupo Tecma Red & SmartGridsInfo. (2020). *Libro de Comunicaciones VII Congreso Smart Grids 2020*. Madrid, España: Grupo Tecma Red & SmartGridsInfo.
- Herzen, J. (5 de Mayo de 2022). *Transfer Learning for Time Series Forecasting*. Obtenido de Medium: <https://medium.com/unit8-machine-learning-publication/transfer-learning-for-time-series-forecasting-87f39e375278>
- Hosseini Imani, M., Bompard, E., Colella, P., & Huang, T. (2025). Data analytics in the electricity market: a systematic literature review. *Energy Systems, Springer*, 16(1), 1-35.
- International Smart Grid Action Network (ISGAN), T. C. (2025). *ISGAN Annual Report 2024: for the period from 1 March 2024 – 28 February 2025*. ISGAN (under the IEA TCP) & International Energy Agency.
- Kofi Nti, I., Teimeh, M., Nyarko-Boateng, O., & Adekoya, A. F. (2020). Electricity load forecasting: A systematic review. *Journal of Electrical Systems and Information Technology, Springer & Elsevier*, 1–19.
- Laitsos, V., Vontzos, G., Paraschoudis, P., Tsampasis, E., Bargiotas, D., & Tsoukalas, L. (2024). The State of the Art Electricity Load and Price Forecasting for the Modern Wholesale Electricity Market. *Energies, MDPI*, 17(22).
- Lara-Benítez, P., Carranza-García, M., M. Luna-Romera, J., & C. Riquelme, J. (2020). Temporal Convolutional Networks Applied to Energy-Related Time Series Forecasting. *Applied Sciences, MDPI*, 1–21.
- Mazzeo, A., Sepúlveda-Cano, L., F. Villa, L., & Gallego-Burgos, R. (2019). Revisión sistemática de literatura sobre modelos de pronósticos de consumo de energía eléctrica. *Revista Ingeniería y Universidad, Pontificia Universidad Javeriana*, 119–143.
- Melgar García, L., Torres Maldonado, J. F., Troncoso, A., & Riquelme Santos, J. C. (2024). Técnicas Big Data para la Predicción de la Demanda y Precio Eléctrico. *Economía Industrial, Ministerio de Industria*, 119-130.
- Monteiro, F., Oliveira, R., Almeida, J., Gonçalves, P., Bartolomeu, P., Neto, J., & Deus, R. (2024). Electricity consumption dataset of a local energy cooperative. *Data in Brief, Elsevier*, 54(110373).

- Olçay, K., Tunca, S. G., & Özgür, M. A. (2024). Forecasting and Performance Analysis of Energy Production in Solar Power Plants Using Long Short-Term Memory (LSTM) and Random Forest Models. *IEEE Access, IEEE*, 12, 104663–104674.
- Pan, X. (2024). The Comparison Between Random Forest and LSTM Models Based on the Gold Price Prediction. *Advances in Economics, Management and Political Sciences, Universiti Putra Malaysia & AEMPS*, 94, 102-108.
- Powergrid, N. (20 de Junio de 2025). *Smart meters, smarter energy*. Obtenido de Northern Powergrid: <https://www.northernpowergrid.com/news-and-events/smart-meters-smarter-energy>
- Torres Sánchez, A. (2023). Predicción de la Demanda de Energía Eléctrica Usando Modelos de Inteligencia Artificial para Series Temporales. Medellín, Antioquia, Colombia: Universidad de Antioquia.
- Uppal, M., Kumar Garg, V., & Kumar, D. (2020). Weather Biased Optimal Delta Model for Short-Term Load Forecast. *IET Smart Grid, IET*, 625–633.
- Waseem Ahmad, M., Mourshed, M., & Rezgui, Y. (2017). Trees vs Neurons: Comparison between Random Forest and ANN for High-Resolution Prediction of Building Energy Consumption. *Energy and Buildings, Elsevier*, 77–89.